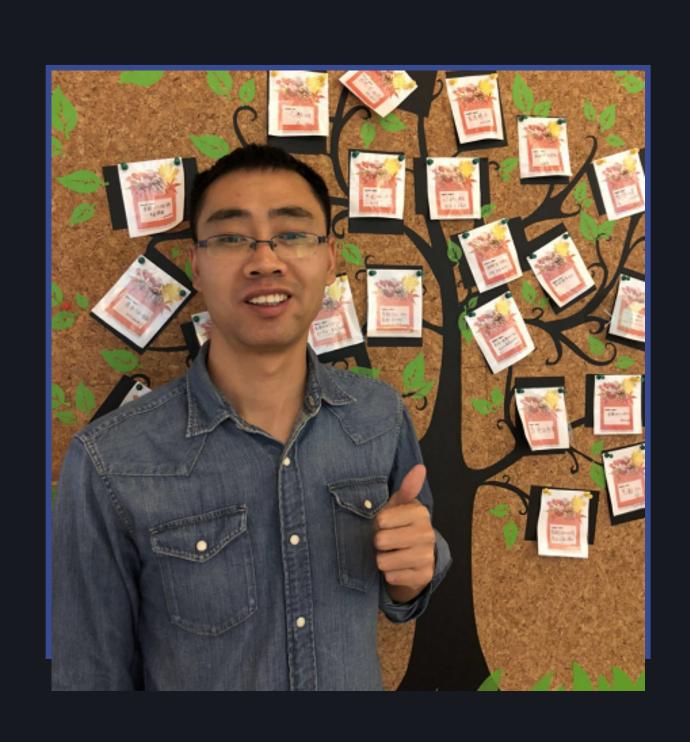




腾讯企业级消息中间件 DevOps之路



SPEAKER INTRODUCE



闫二辉(zizayan)

腾讯中间件专家工程师,2012年加入腾讯基础架构部

主要从事:

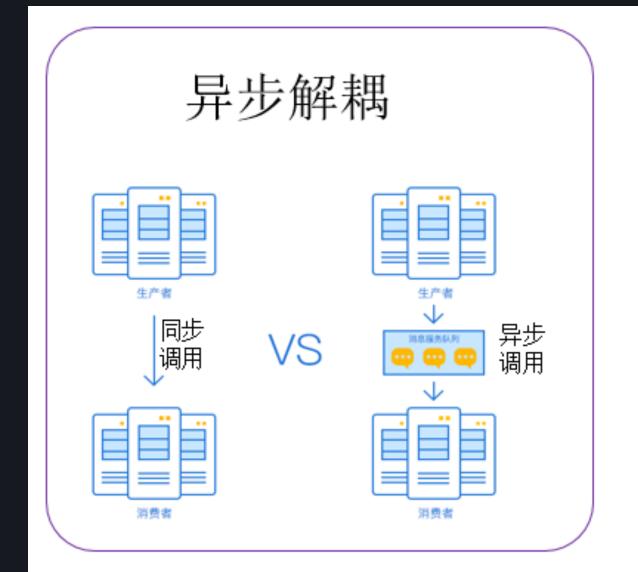
- > 腾讯分布式服务开发框架TSF:微服务开发和生命周期管理PaaS平台
- > 消息中间件CMQ、CKafka: 高可靠、强一致、高弹性分布式消息服务
- > IoT Hub :安全、高并发、多协议设备接入与规则引擎解析

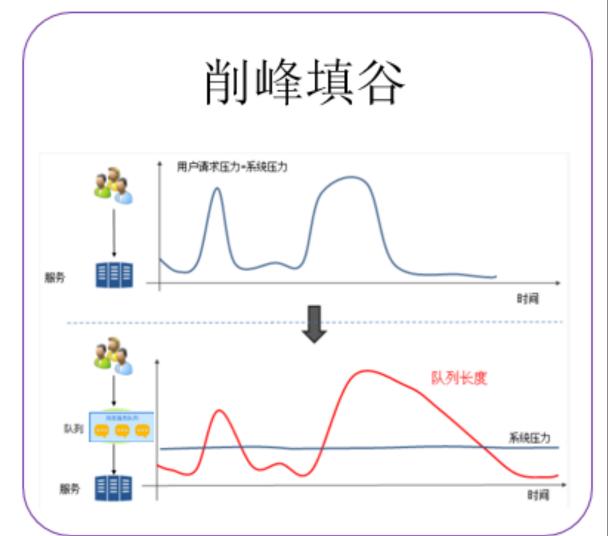
TABLE OF

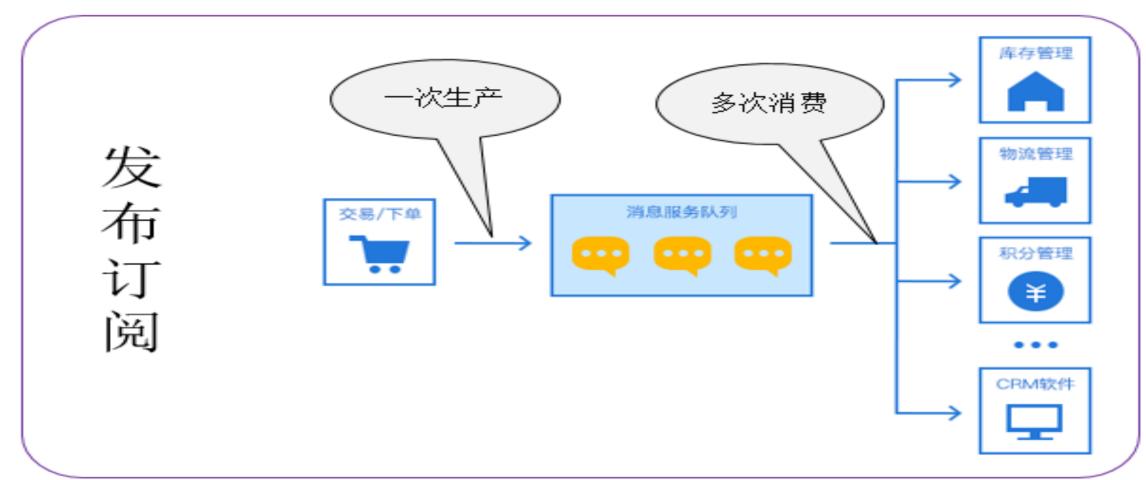
CONTENTS 大纲

- 背景介绍
- 从开发、运维维度解析核心原理
- 分布式消息系统对测试的挑战
- 微信红包中如何使用消息中间件

消息中间件应用场景



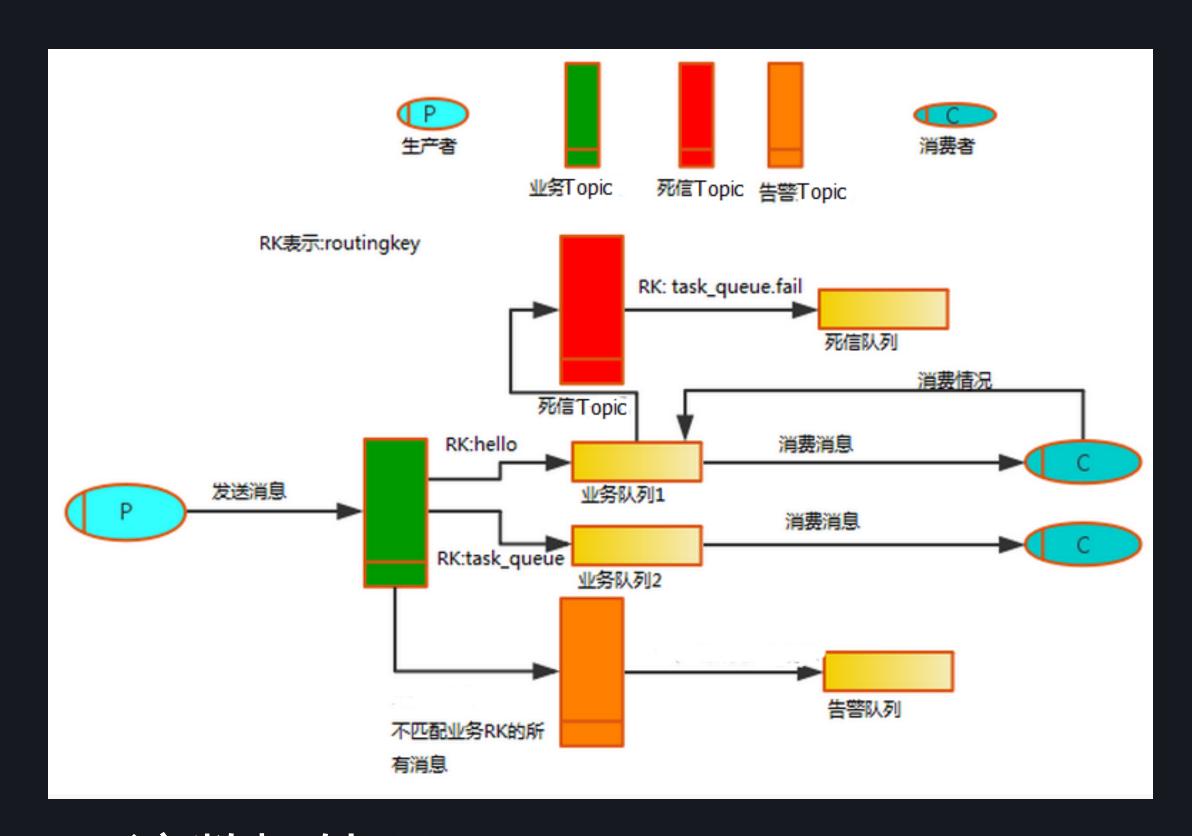




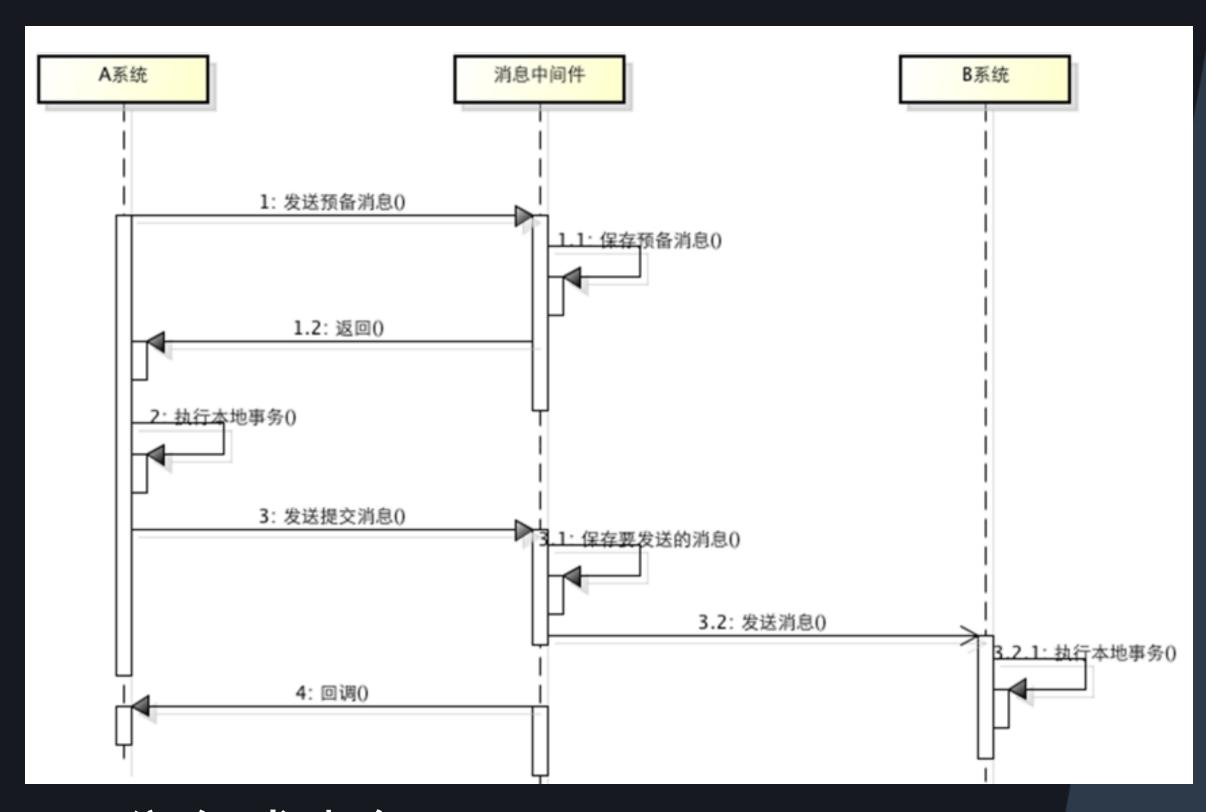
- 》业务解耦:
 同步变异步最终一致
- 》削峰限流: 防止雪崩 按需消费
- 》广播: 透明生产 谁需要谁订阅
- 延时消费:定时触发-简化业务逻辑
- 》回档消费: 离线消费-从指定点消费



消息中间件应用场景



流数据处理: 按需对消息过滤分类 简化业务程序逻辑



》分布式事务 多个本地事务 简单。高效,最终一致





背景介绍

CRMQ-Rabbitmq 2012内部大规模使用 CRMQ-Raft 2014年自研2.0 CMQ 2016年上线腾讯云

Ckafka 2014年开始内部使用

Ckafka 2017年上线腾讯云

- ➤ CMQ: 金融级别,多副本,高可靠,强一致,多级容灾
- ➤ Ckafka: 大数据领域,高吞吐,低延时
- > MQ for IoT: MQTT接入,支持干万并发,安全性高
- > 内部日消息量:超万亿条
- >接入业务个数:超万个





分布式消息系统特点

最大特点:可扩展性(Scale Out)

核心理念:多个节点协同工作,完成单个节点无法处理的任务

对硬件要求低

强调横向可扩展性

不允许出现单点故障服务不可用(RTO)

不允许单点故障导致数据丢失(RPO)

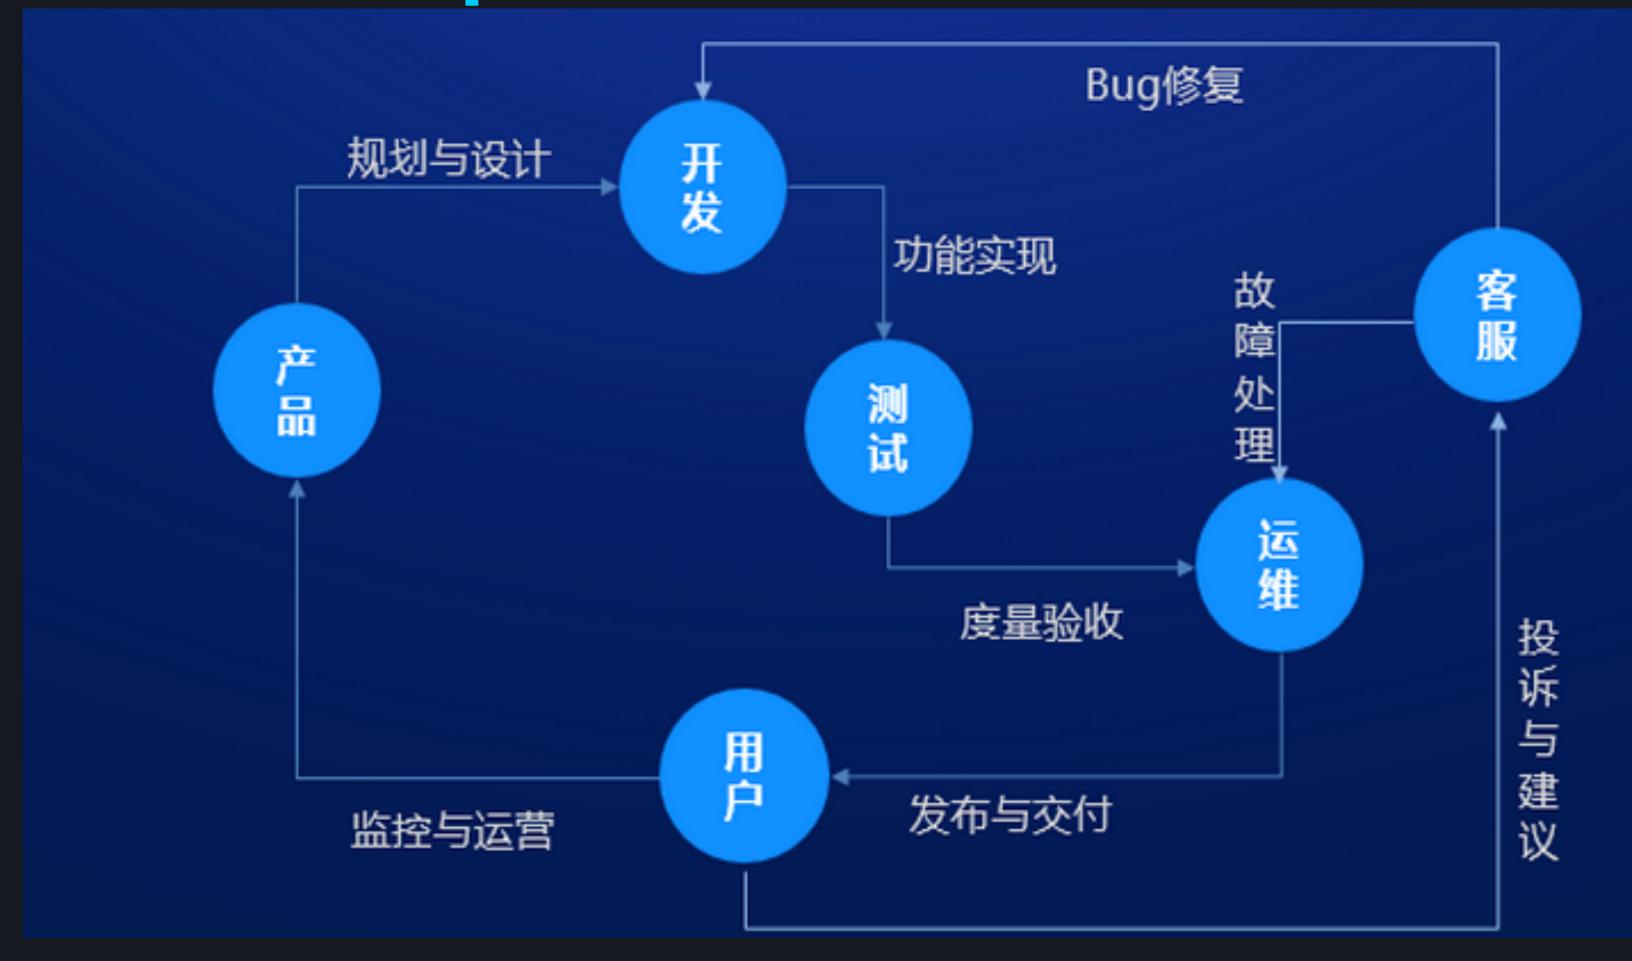
核心问题: CAP

CMQ: CP

Kafka: AP(配置可调整)



DevOps 流程



- 产 开发阶段:方案设计、代码设计、LLT(单元测试、模块测试);
- 》测试阶段:测试设计、自动化脚本、HLT(系统测试、联调测试);
- 灰度阶段:灰度规则和策略、灰度测试设计、监控告警;
- 》上线阶段:定时在线测试 设计、日常运营监控告警

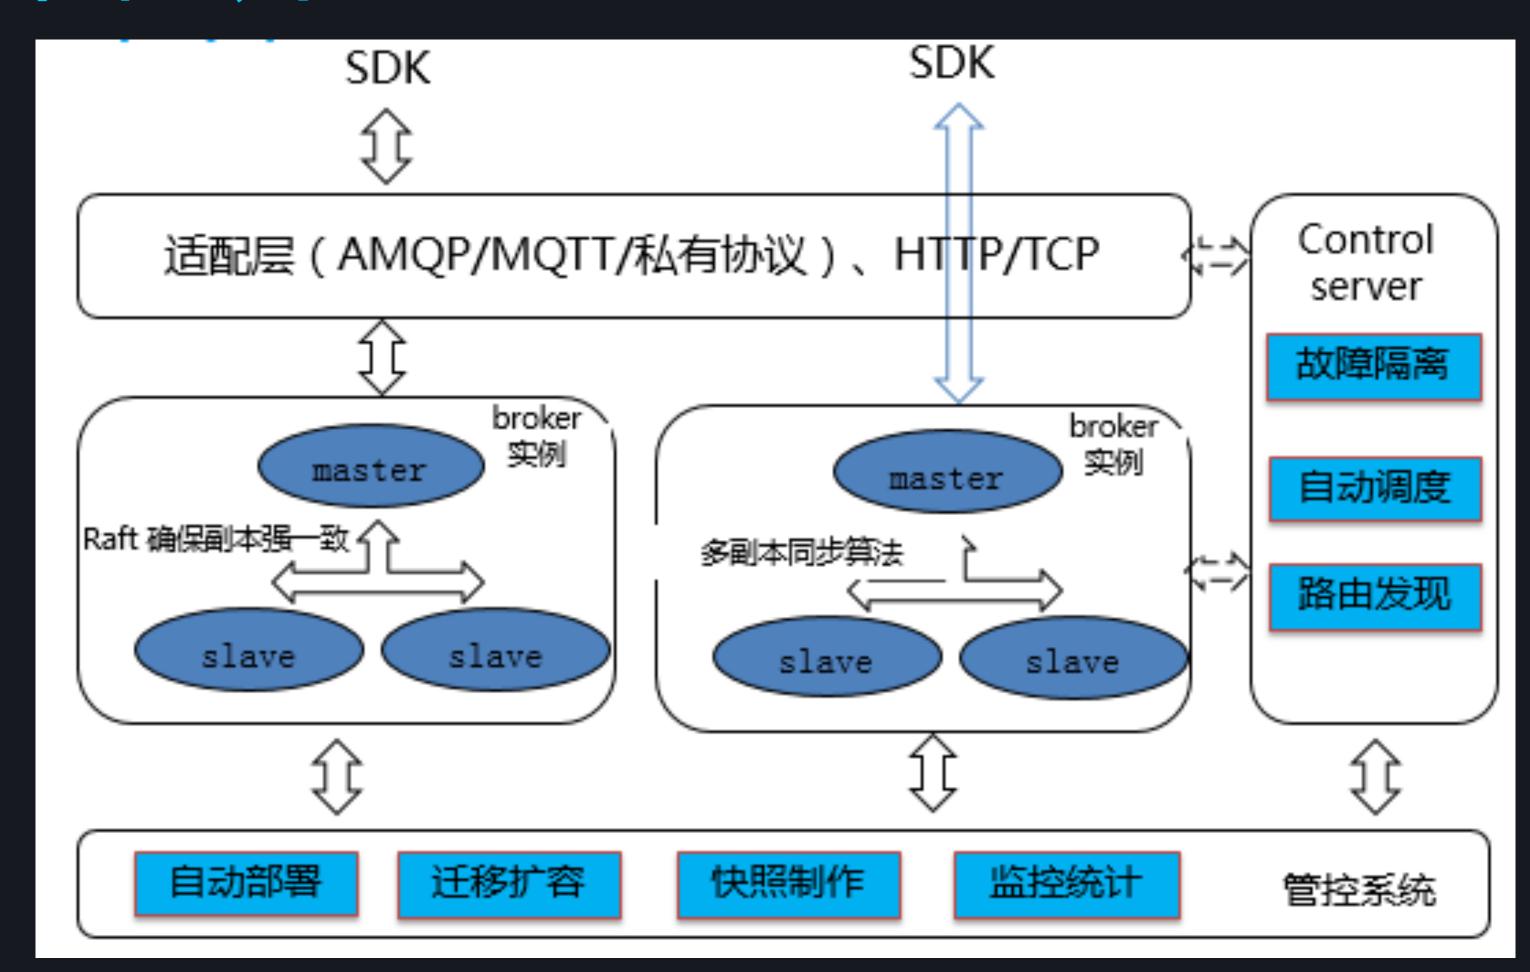


TABLE OF

CONTENTS 大纲

- 背景介绍
- 从开发、运维维度解析核心原理
- 分布式消息系统对测试的挑战
- 微信红包中如何使用消息中间件

架构介绍



典型三层架构

- 》 适配层: 协议解析 弹性伸缩

> 运营难点:如何做到发布变更对业务透明?

如何做到弹性扩展?

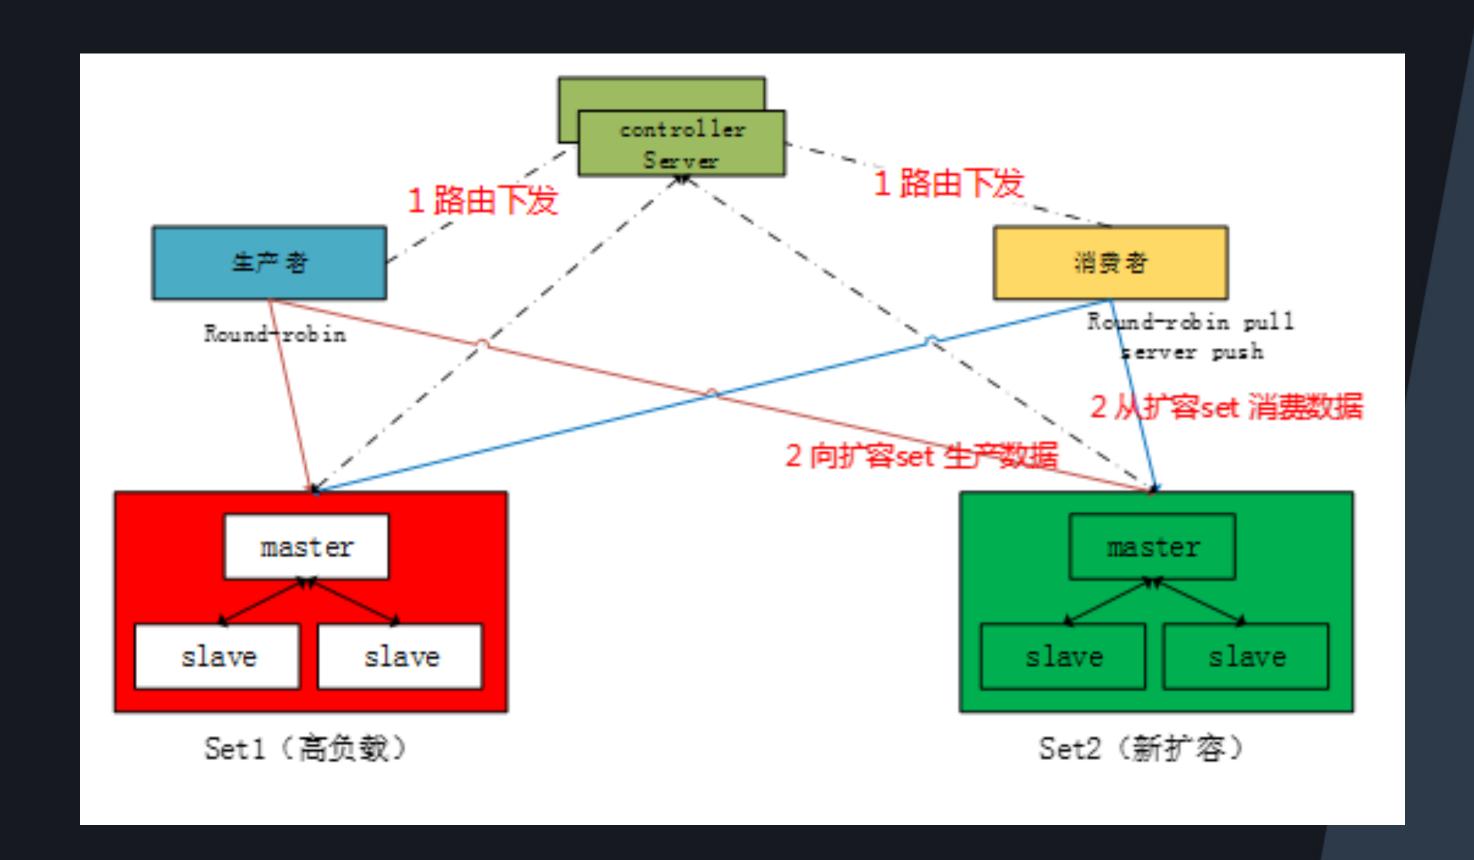
节点故障如何处理? 集群故障如何处理,园区级别故障如何处理?





弹性伸缩

- ➤ 问题:性能和堆积不受限与set,支持透明scale out,可以无限扩展
 - ✓ Controller server: 向生产者消费者 下发扩缩容路由信息;
 - ✓生产: 获取路由信息, 轮询多个broker set 实现消息生产
 - ✓消费: 获取路由信息, 通过轮询主动拉或者 server 推的方式消费数据





高可靠(1/2)

- ▶ 数据可靠性:系统有n个数据对象,在1年内会损坏m个对象,可靠性为1-m/n
- > 可靠性相关因子:副本数、磁盘故障率、修复率
- ➤ 常见 master+Nslave数据多副本问题:
 - ✓数据一致性问题:异步复制会导致slave上数据丢失,同步复制到所有slave导致系统可用性低
 - ✓同步复制性能问题:每个请求都发起一次主从数据同步,导致系统性能低下
 - ✓持久化问题:在master、slave cache中还未来得及持久化到磁盘的数据存在异常情况下丢失的可能
 - ✓ 刷盘性能问题:每个请求都强制刷盘一次,导致系统IO负载高



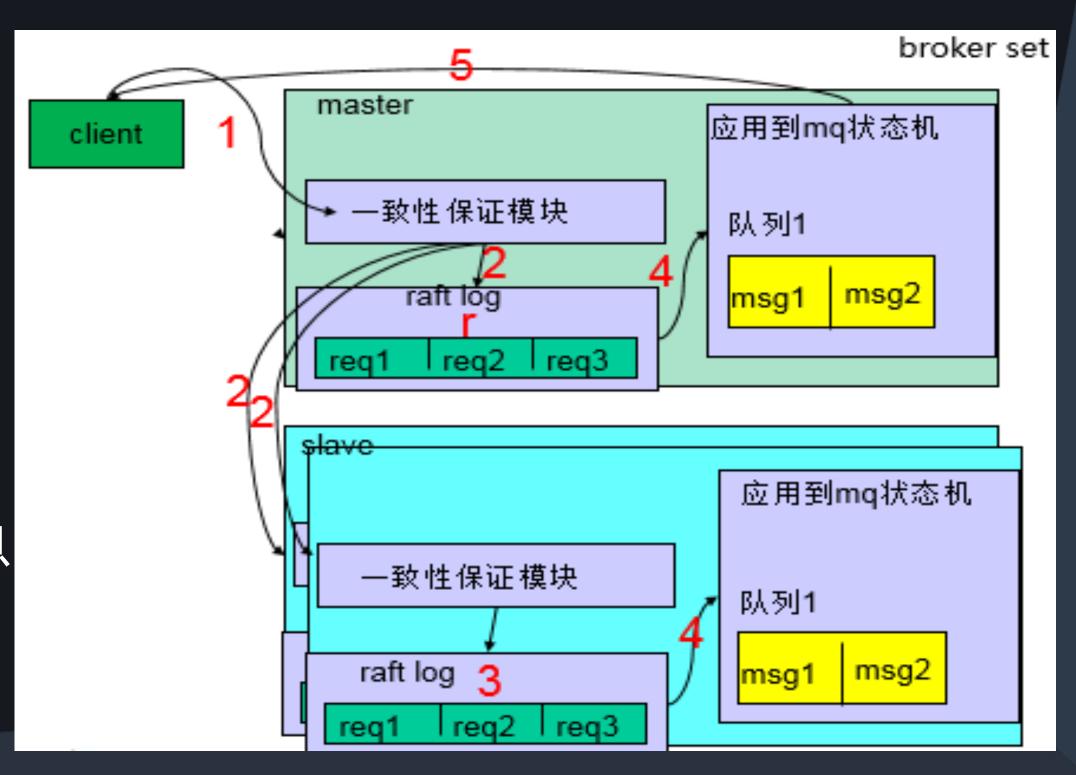
高可靠(2/2)

> 问题:异步复制无法保证强一致,同步复制到所有slave导致可用性低

✓方案:master同时向所有slave同步数据, salve 收到数据存储成功后向master返回成功, master 收到过半数节点返回成功后应用到mq状态机,返回用户成功。

举例:一个set 有3个节点组成,自动选举出一个master,两个slave

- Master 负责消息的生产消费请求,收到请求后先通过raft—致性模块写raft log到本地并同步给所有slave
- Slave 收到master发来的raft log持久化到本地同时返回master 成功信息
- Master 收到set中过半节点的成功信息后将请求信息 提交到mg 状态机
- · Mq 状态机处理请求信息后返回用户成功





高性能(1/2)

> 问题:同步复制性能问题

Master每收到一个请求都向所有slave各发起一次网络IO, slave 处理成功后回复master成功。 Master 和slave 还需要对收到的请求同步刷盘

> 分析:单次请求同步复制下,同步刷盘耗时:

```
✓T<sub>total</sub>=T<sub>creat_raft_log</sub>+T<sub>master_fsync_raft_log</sub>+T<sub>replicate_raft_log</sub>+T<sub>apply_raft_log</sub>
✓T<sub>creat_raft_log</sub>、 T<sub>write_raft_log</sub> T<sub>apply_raft_log</sub> 受限单机处理性能
✓T<sub>replicate_raft_log</sub>=T<sub>raft_log网络传输+</sub>T<sub>slave_fsync_raft_log</sub>, T<sub>raft_log网络传输</sub>取决于RTT值
```

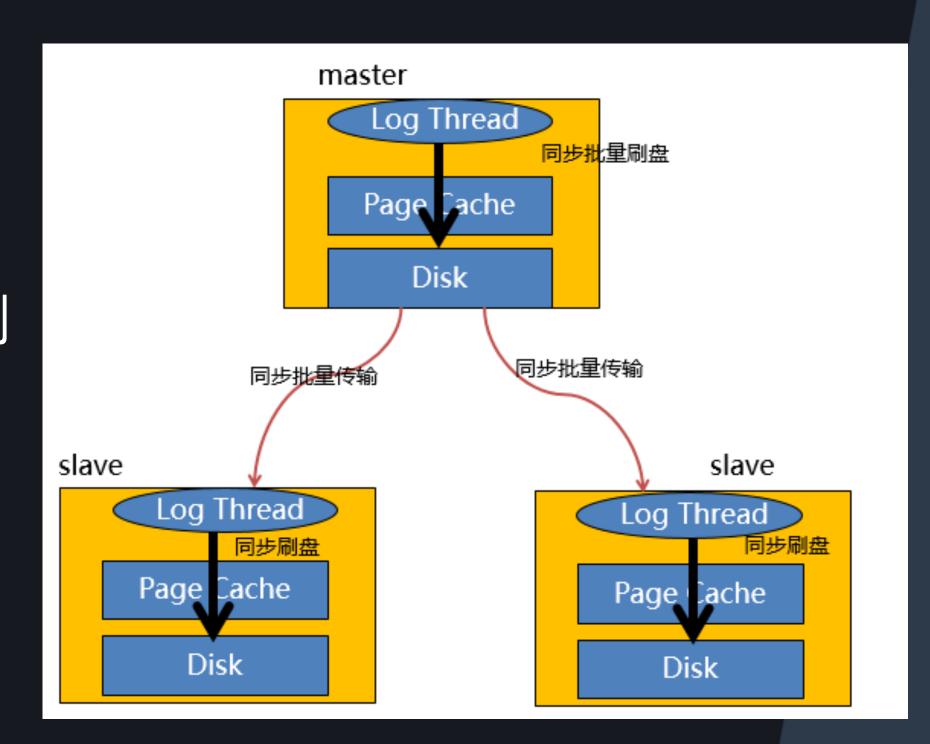
$$\sqrt{T_{total}} = T_{creat_raft_log} + T_{master_fsync_raft_log} + T_{raft_log网络传输} + T_{slave_fsync_raft_log} + T_{apply_raft_log}$$

fsync_raft_log时间取决于磁盘性能, raft_log 网络传输时间取决于网络RTT。由此可见这两个值是硬 件相关的,因此我们只能通过提高每次批量发送raft_log 和批量fsync 刷盘来提高QPS(在牺牲一定请求延 时情况下,可配置)



高性能(1/2)

- > 解决思路:批量同步、批量刷盘提升性能
- > 具体方法:
 - ✓批量fsync: master 通过定时、定量两个维度合并请求批量刷盘,提高QPS(可配置)
 - ✓ 批量发送raft log到slave: 同上
 - ✓ 严格同步刷盘: master slave 遵循fsync 后才返回成功的逻辑, 确保异常断电、宕机情况下的数据100%不丢失。





节点可用性

- ➤ 问题:当set内节点间发生网络分区时如何确保数据一致性?
- ✓当slave 单独在一个分区时,master可以得到过半数节点的应答,无任何影响;
- ✓ 当master 单独成为一个分区时由于得不到大多数节点的应答,超时后最合适的 salve

会 提升为master

✓具体过程:

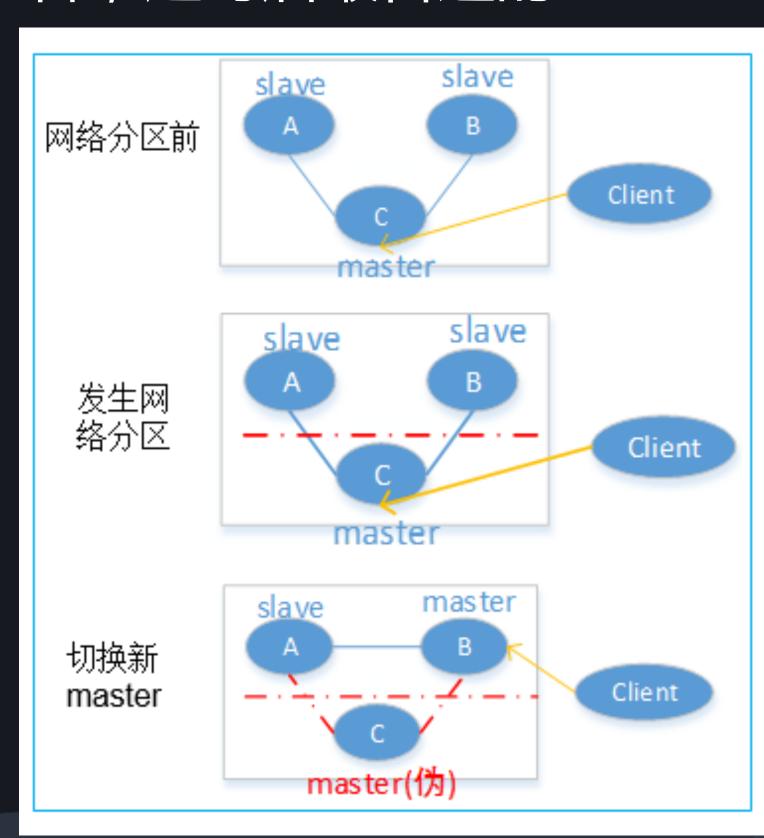
关键变量:

- Log序号 (index)
- Master任期号 (term)

Raft Log同时记录了index和term。

Raft数据同步核心思想:

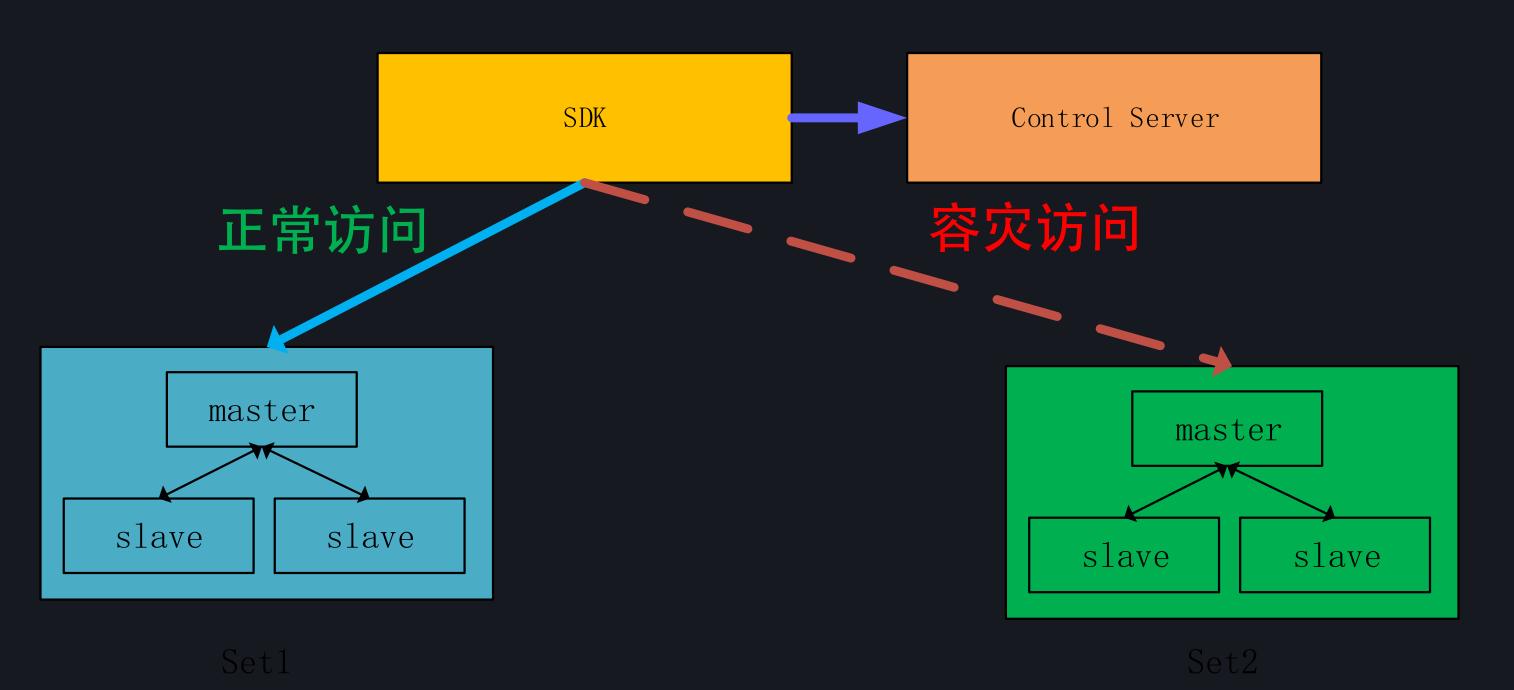
- 1) Master通过选举产生,同时产生了一个新的term,且新term > 老term
- 2) Slave只接受大于或者等于当前term的连续log。
- 3) Master根据Slave的上一条log和term,发送差量log,实现数据一致性。





集群可用性

-)问题:raft解决了单节点 故障导致的可用性问 题,如果同一个set内多 个节点故障,怎么办?
- > 解决方案:双SET服务能力

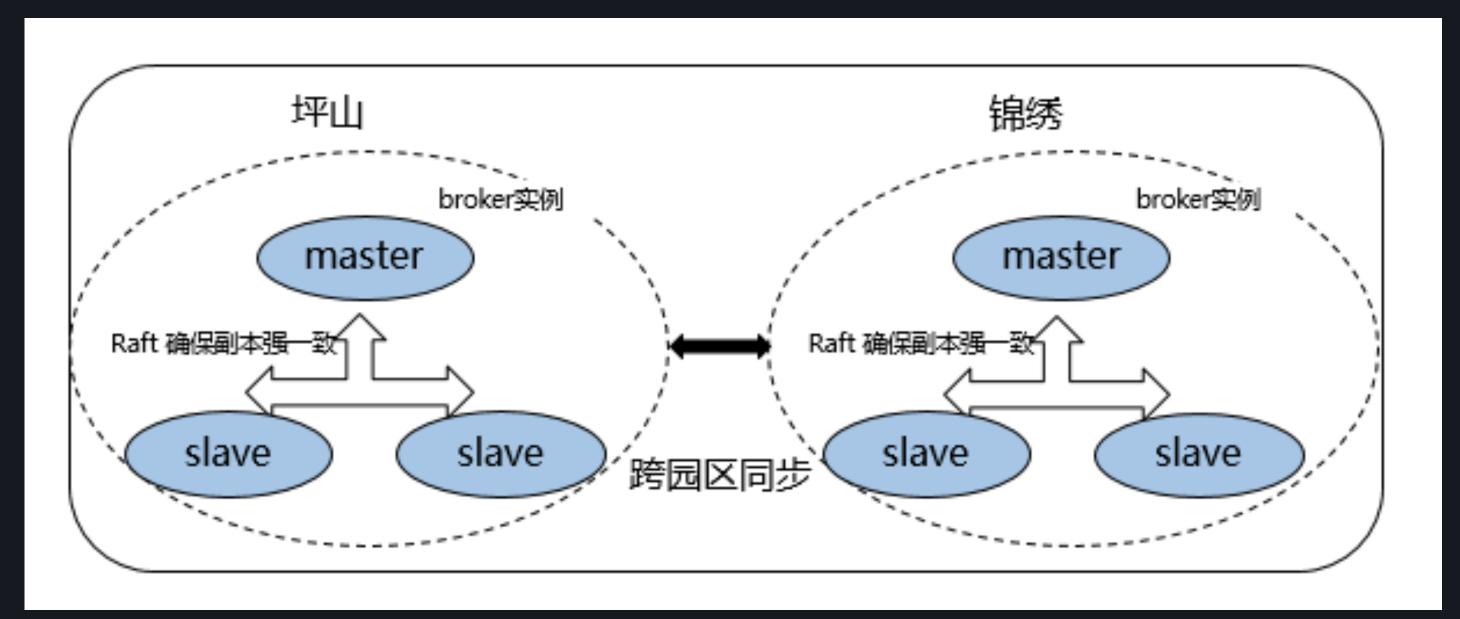


- ✓ 分别在两个set创建Topic/Queue元数据
- ✓ 一个Set真正对外服务,另外一个standby
- ✓ Set内节点故障选举时间最大2s, Set 间故障切换时间5s
- ✓切换时数据顺序性问题

跨园区可用

> 问题:金融业务要求具备跨园区容灾能力

▶ 思路: set内节点同园区部署,不同园区的set间异步同步数据



- ✔两中心部署:
- 1) 两园区各部署一个set,园区间数据异步复制
- 2) 性能高、园区间数据一致性受异步复制频率和园区间网络质量影响



Log Trace 系统

> 问题:如何满足业务日常定位问题需求?消息丢了,延时大了。。。



✓全路径日志追踪:

- 1) 支持对消息的生产消费全流程trace,
- 2) 方便查看消息延时,是否丢失,投递几次等常见运维问题



TABLE OF

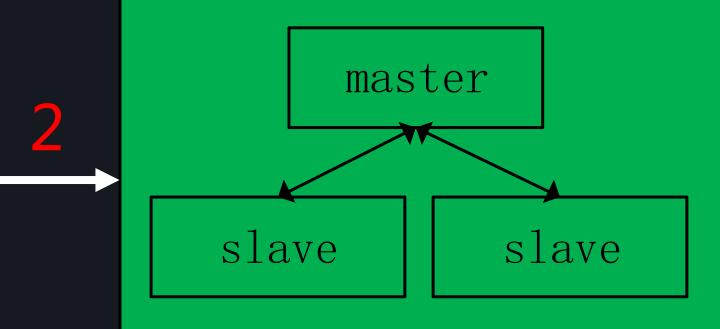
CONTENTS 大纲

- 背景介绍
- 从开发、运维维度解析核心原理
- 分布式消息系统对测试的挑战
- 微信红包中如何使用消息中间件

分布式消息系统测试

- > 做好分布式系统的测试比做分布式系统本身更难
- 〉设计的时候就要考虑如何测试这个特性
 - ✓功能测试
 - ✓压力测试
 - ✓ 异常注入测试
 - ✓ 一致性测试

至文件测试式 Control Node Cilent Cilent Generator Cilent Cilent



- 部署要测试的集群
- ➤ Control Node执行测试程序
 - ✓启动集群
 - ✓ 生产5个执行序列
 - ✓ 5个线程执行序列
 - · 调用Client执行请求
 - 通过SSH登录N1-N2注入故障
- ▶记录执行结果
- ➢验证执行结果
- > 停止集群分析结果

Nemesis

4

Shape Shape

Model



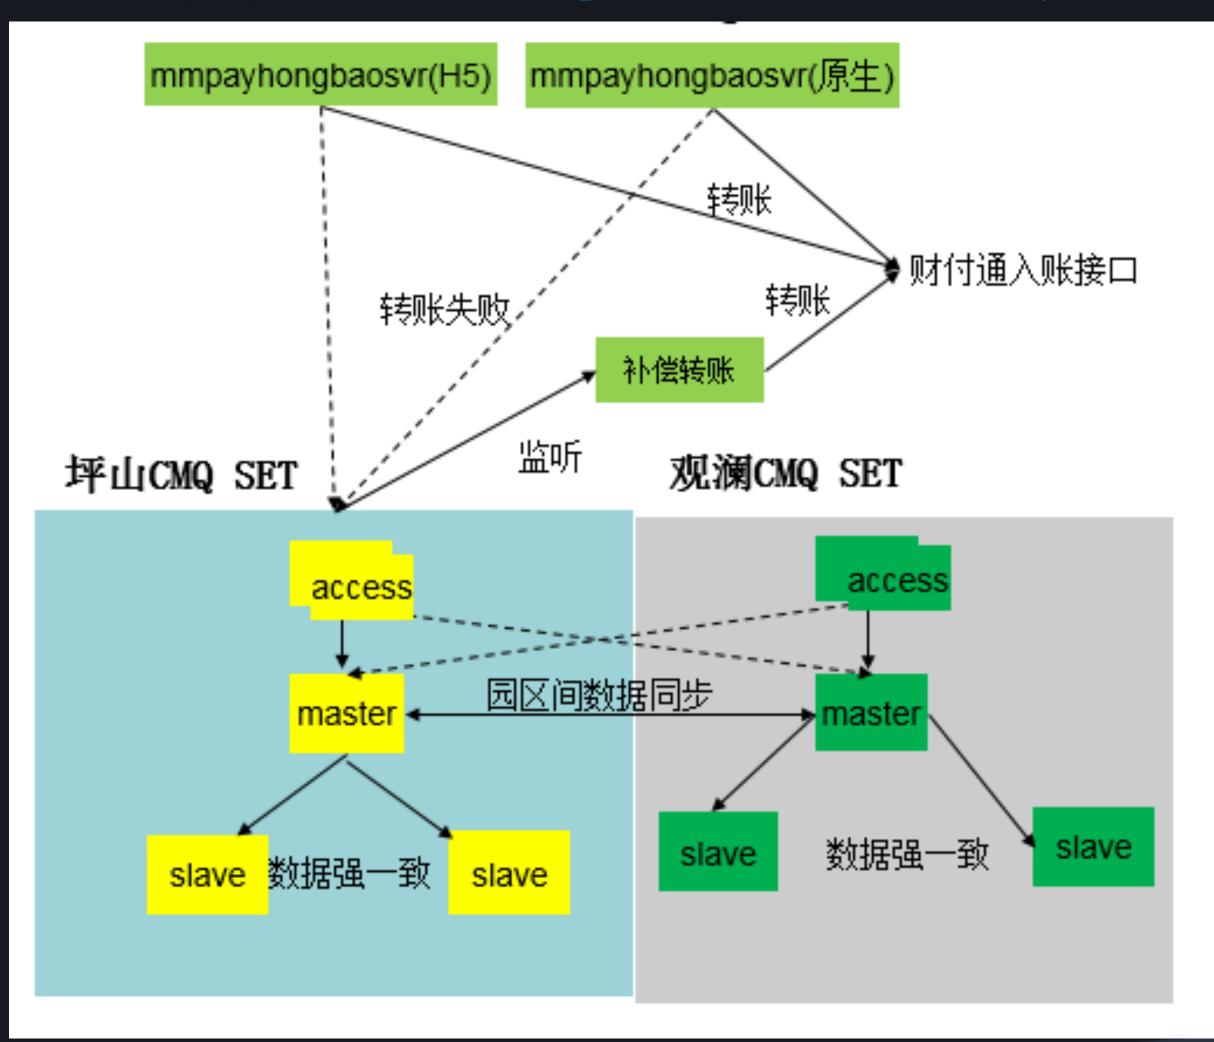
TABLE OF

CONTENTS 大纲

- 消息中间件应用场景
- 腾讯消息中间件核心技术原理解析
- 分布式系统对开发、测试、运维的挑战
- 微信红包中如何使用消息中间件



微信红包中如何使用消息中间件



- 》目标:应对财付通转账接口异常, 列表更新异常,回调写用户信息异常等场景,缓存失败请求,由独立 模块补偿重试。
- ➢对消息中间件的要求: 高可靠 强一致 高性能

THANKYOU

如有需求,欢迎至[讲师交流会议室]与我们的讲师进一步交流

